Prevendo Despesas Hospitalares_v2

Evanil Tiengo Junior

Índice

Introdução

Este projeto faz parte da formação Big Data Analytics com R e Microsoft Azure da DSA. Para esta análise, é usado um conjunto de dados simulando despesas médicas hipotéticas para um conjunto de pacientes espalhados por 4 regiões do Brasil. Esse dataset possui 1.338 observações e 7 variáveis. Todo o projeto será descrito de acordo com suas etapas.

Objetivos

1) Empregar técnicas de análise para verificar as correlações entre as variáveis;

2) Criar um modelo que faça as previsões, quanto aos gastos de um usuário, quando receber novos conjuntos de dados;

3) Analisar as métricas do modelo e tirar conclusões o mesmo.

```
# Local armazenamento
setwd("~/Desktop/Projeto/Projeto3")
getwd()

## [1] "~/Desktop/Projeto/Projeto3"
```

```r
# Pacotes utilizados.
#install.packages("dplyr")
library(dplyr)
```

```
##
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
##
##     filter, lag
```

```
## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union
```

```r
#install.packages("tidyr")
library(tidyr)
#install.packages("ggplot2")
library(ggplot2)
#install.packages("psych")
library(psych)
```

```
##
## Attaching package: 'psych'
```

```
## The following objects are masked from 'package:ggplot2':
##
##     %+%, alpha
```

```r
#install.packages("corrplot")
library(corrplot)
```

```
## corrplot 0.84 loaded
```

```r
#install.packages("caTools")
library(caTools)
#install.packages("car")
library(car)
```

```
## Loading required package: carData
```

```
##
## Attaching package: 'car'
```

```
## The following object is masked from 'package:psych':
##
##     logit
```

```
## The following object is masked from 'package:dplyr':
##
##     recode
```

Etapa 1 - Coletando os Dados

Os dados foram fornecidos pela DSA. Sendo assim preciso realizar a carga. Antes de realizar a carga do arquivo é necessário saber o formato do mesmo, que neste caso é .csv!

```
Despesas <- read.csv("~/Desktop/Projeto/Projeto3/despesas.csv")
```

Etapa 2 - EDA (Exploratory Data Analysis)

```
# Com o comando abaixo é possível identificar as classes de cada variável
str(Despesas)
```

```
## 'data.frame':    1338 obs. of  7 variables:
##  $ idade  : int  19 18 28 33 32 31 46 37 37 60 ...
##  $ sexo   : Factor w/ 2 levels "homem","mulher": 2 1 1 1 1 2 2 2 1 2 .
..
##  $ bmi    : num  27.9 33.8 33 22.7 28.9 25.7 33.4 27.7 29.8 25.8 ...
##  $ filhos : int  0 1 3 0 0 0 1 3 2 0 ...
##  $ fumante: Factor w/ 2 levels "nao","sim": 2 1 1 1 1 1 1 1 1 1 ...
##  $ regiao : Factor w/ 4 levels "nordeste","norte",..: 3 4 4 1 1 4 4 1
2 1 ...
##  $ gastos : num  16885 1726 4449 21984 3867 ...
```

```
# Para a previsão irei utilizar a Regressão Linear Múltipla. Sendo assim,
irei transformar algumas variáveis em numéricas. Essa transformação é pos
sível pois as variáveis não numéricas são fatores (Têm níveis)

# $sexo: mulher = 1; homem = 2
Despesas$sexo <- as.numeric(Despesas$sexo)

# $fumante: sim = 1; não = 2
Despesas$fumante <- as.numeric(Despesas$fumante)

# $regiao: nordeste = 1; norte = 2; sudeste = 3; sul = 4
Despesas$regiao <- as.numeric(Despesas$regiao)

str(Despesas)
```

```
## 'data.frame':    1338 obs. of  7 variables:
##  $ idade  : int  19 18 28 33 32 31 46 37 37 60 ...
##  $ sexo   : num  2 1 1 1 1 2 2 2 1 2 ...
##  $ bmi    : num  27.9 33.8 33 22.7 28.9 25.7 33.4 27.7 29.8 25.8 ...
##  $ filhos : int  0 1 3 0 0 0 1 3 2 0 ...
##  $ fumante: num  2 1 1 1 1 1 1 1 1 1 ...
##  $ regiao : num  3 4 4 1 1 4 4 1 2 1 ...
##  $ gastos : num  16885 1726 4449 21984 3867 ...
```

```
# Identificação de NA`s e Vazios!
any(is.na(Despesas))
```

```
## [1] FALSE
```

```
any(Despesas == "")
```

```
## [1] FALSE
```

```
# False significa que não existe nenhum campo com NA ou Vazio!

# Abaixo temos um resumo dos dados
str(Despesas)
```

```
## 'data.frame':    1338 obs. of  7 variables:
##  $ idade  : int  19 18 28 33 32 31 46 37 37 60 ...
##  $ sexo   : num  2 1 1 1 1 2 2 2 1 2 ...
##  $ bmi    : num  27.9 33.8 33 22.7 28.9 25.7 33.4 27.7 29.8 25.8 ...
##  $ filhos : int  0 1 3 0 0 0 1 3 2 0 ...
##  $ fumante: num  2 1 1 1 1 1 1 1 1 1 ...
##  $ regiao : num  3 4 4 1 1 4 4 1 2 1 ...
##  $ gastos : num  16885 1726 4449 21984 3867 ...
```

```
# Aqui podemos tirar algumas observações:
```

Após os testes acima, conclui-se que os dados estão ok!

```
# Medidas da tendencia central da variavel $gastos
ggplot(Despesas, aes(gastos)) +
geom_histogram(color = "#429FFF", fill = "#429FFF")
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

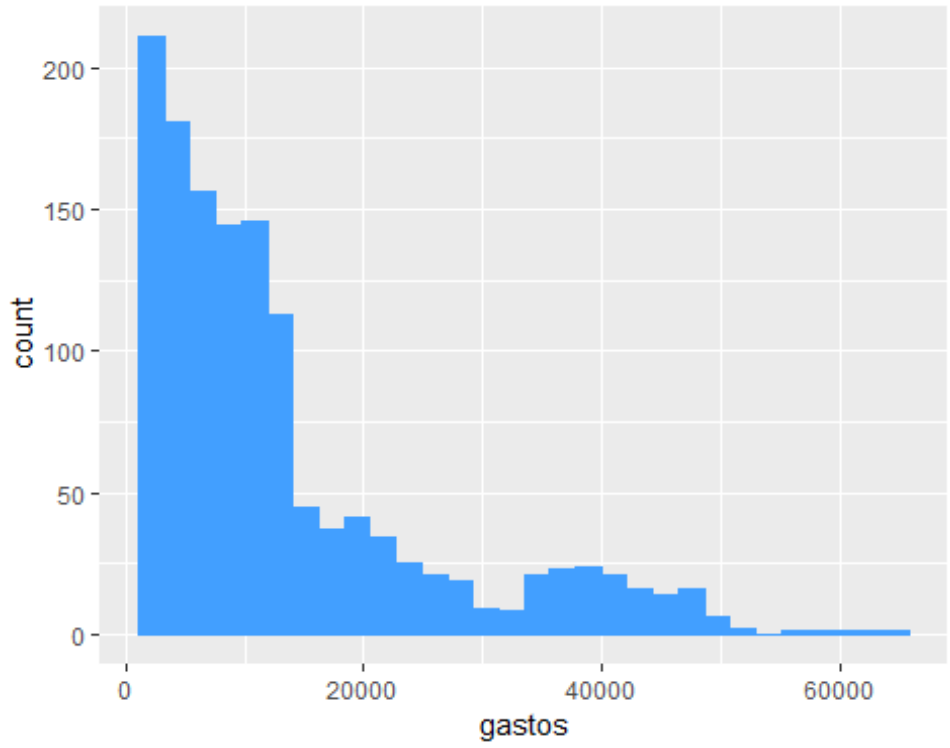

Pelo histograma podemos identificar uma distribuição Unimodal e um enviesamento a direita (Mediana < Media). Com isso podemos observar que a distribuição dos dados concentra-se em torno dos valores mínimos. Como pode ser observado no resumo, o 3rd Quartil que representa 75% dos valores, é igual a 16640 reais. Isso quer dizer que 75% dos gastos são inferiores a 16640 reais. Vamos fazer um boxplot para confirmar.

```
boxplot(Despesas$gastos)
```

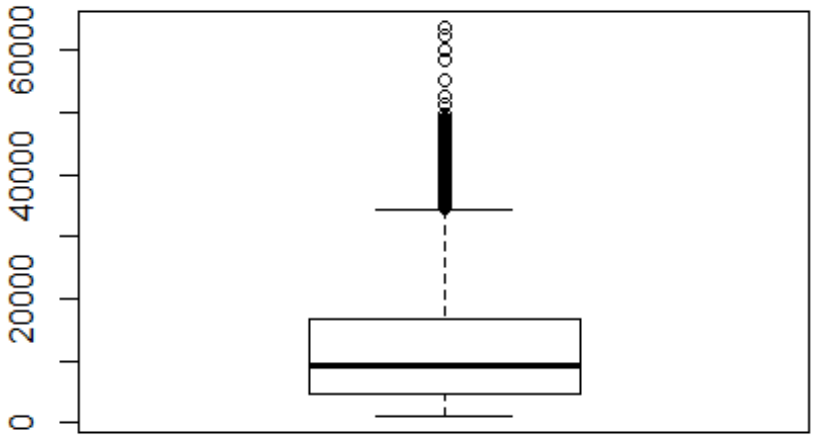

Como pode ser observado temos muitos outliers superiores.

```
# O valor do primeiro outlier é dado pela eq: Q1 + (1.5*IQR)
# O IQR é o Q3 - Q1
IQR = 16640 - 4740
IQR

## [1] 11900

Outlier_Superior = 16640 + (1.5*IQR)
Outlier_Superior

## [1] 34490

#34490
```

Como os valores dos outliers são elevados não irei retira-los do modelo nesse momento. Mais abaixo farei um teste retirando os outliers para saber a influência deles.

Gráfico e Tabela de contingência para analisar a distribuição das variáveis

```
# $idade: distribuição uniforme
hist(Despesas$idade, xlab = "idade")
```

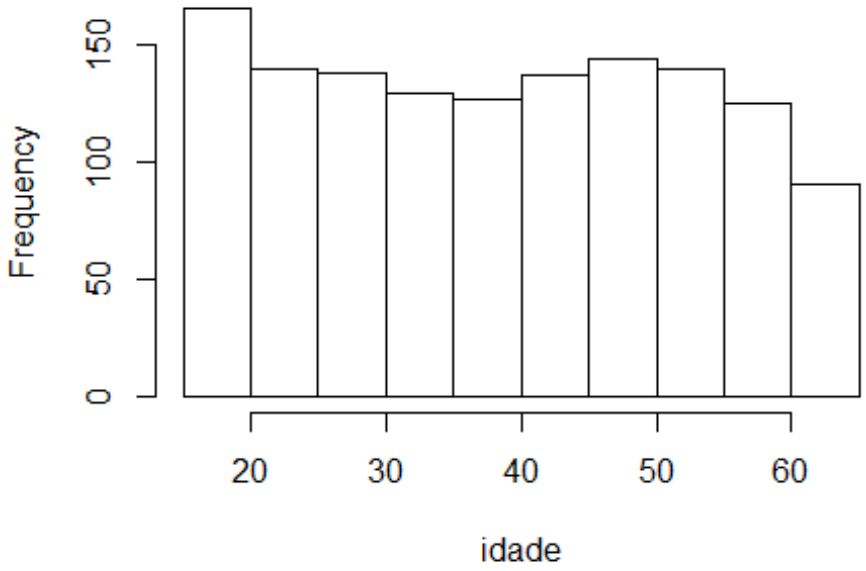


```
count(Despesas, idade)
```

```
## # A tibble: 47 x 2
##    idade     n
##    <int> <int>
##  1    18    69
##  2    19    68
##  3    20    29
##  4    21    28
##  5    22    28
##  6    23    28
##  7    24    28
##  8    25    28
##  9    26    28
## 10    27    28
## # ... with 37 more rows
```

```
# $sexo: distribuição uniforme
hist(Despesas$sexo,  xlab = "sexo")
```

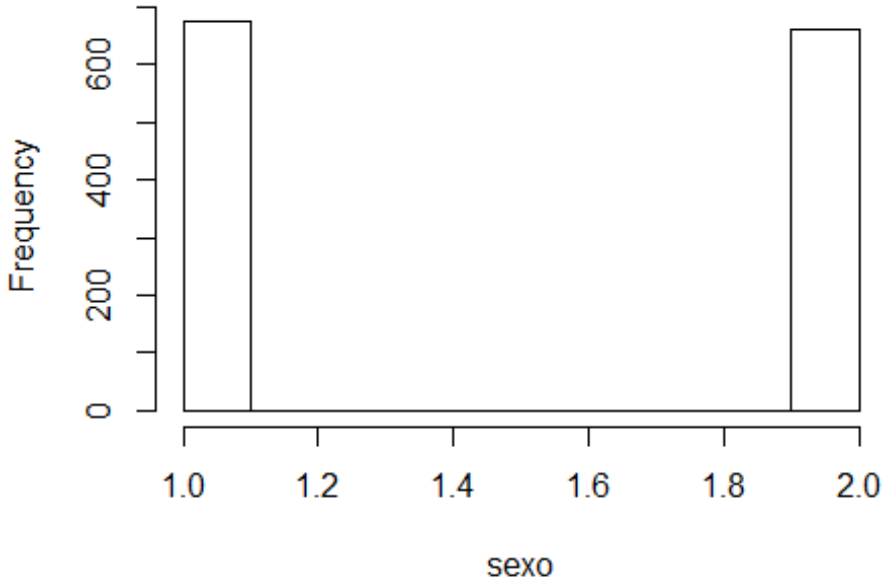


```r
round(prop.table(table(Despesas$sexo)) * 100, digits = 1)
```

```
##
##    1    2
## 50.5 49.5
```

```r
# Em termos de porcentagem temos:
# mulher = 50.5%
# homem = 49.5%

# $bmi: distribuição simetrica.
hist(Despesas$bmi,  xlab = "bmi (Massa corporal)")
```

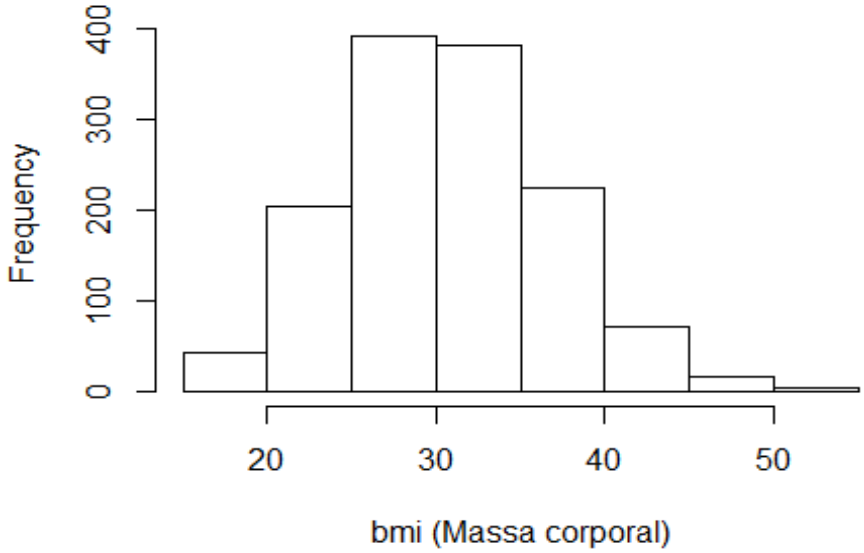

```
count(Despesas, bmi)
```

```
## # A tibble: 275 x 2
##      bmi     n
##    <dbl> <int>
##  1  16       1
##  2  16.8     2
##  3  17.2     1
##  4  17.3     3
##  5  17.4     2
##  6  17.5     1
##  7  17.7     1
##  8  17.8     2
##  9  17.9     1
## 10  18       1
## # ... with 265 more rows
```

Os dados de bmi (massa corporal) fornecidos tendem a centralidade e os valores são mais comuns entre 25 a 35 bmi.

```
# $filhos: distribuição enviesada a direita.
hist(Despesas$filhos,  xlab = "filhos")
```

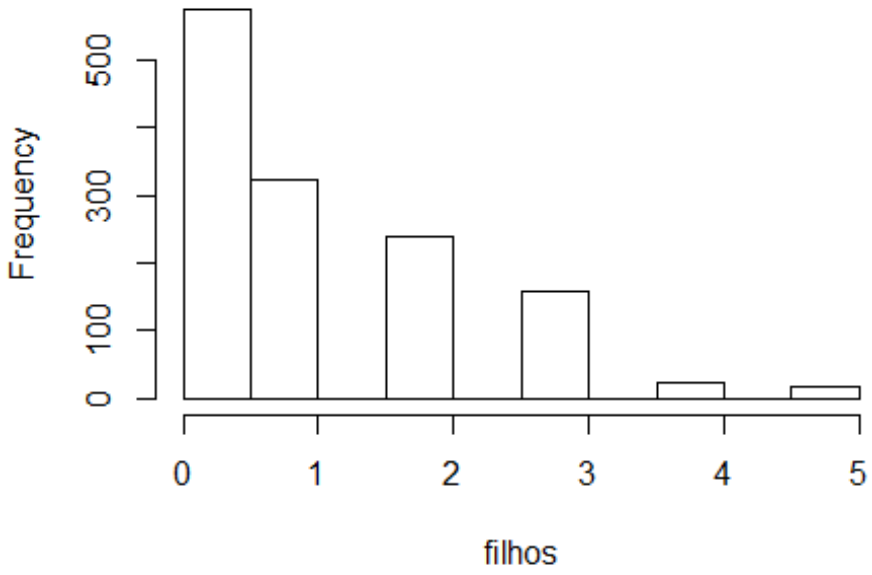


```
table(Despesas$filhos)
```

```
##
##   0   1   2   3   4   5
## 574 324 240 157  25  18
```

Os dados fornecidos tendem a ter um enviesamento a direita, o que indica que a distribuição dos dados concentra-se em torno dos valores mínimos. Em termos de porcentagem temos:

0 filhos -> 574 / 1338 = 42,9%

1 filhos -> 324 / 1338 = 24,2%

2 filhos -> 240 / 1338 = 17,9%

3 filhos -> 157 / 1338 = 11,8%

4 filhos -> 25 / 1338 = 1,9%

5 filhos -> 18 / 1338 = 1,3%

```r
# $fumante: distribuição desequilibrada.
hist(Despesas$fumante,  xlab = "fumante")
```

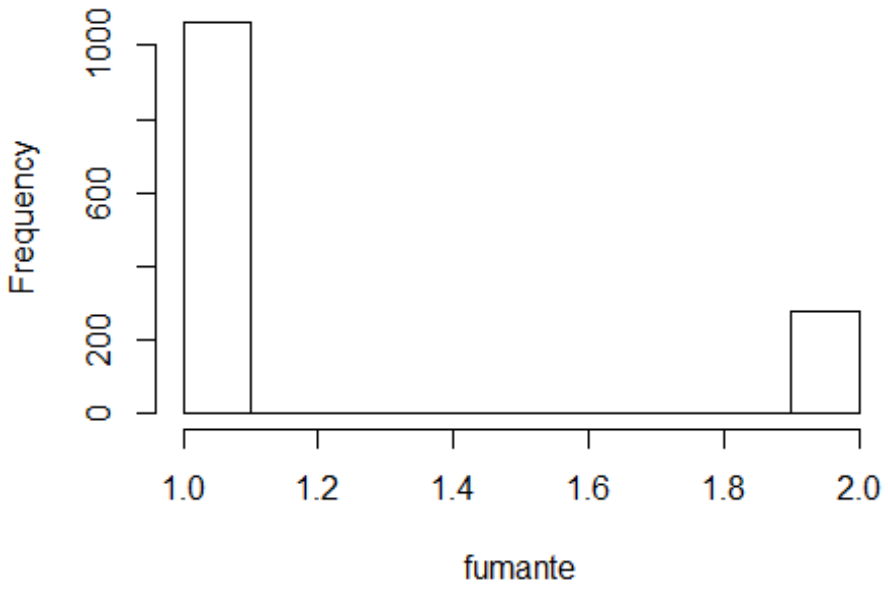


```r
table(Despesas$fumante)
```

```
##
##    1    2
## 1064  274
```

```r
round(prop.table(table(Despesas$fumante)) * 100, digits = 1)
```

```
##
##    1    2
## 79.5 20.5
```

Em termos de porcentagem temos:

Não Fumante -> 1064 / 1338 = 79,5%

Fumante -> 274 / 1338 = 20,5%

```r
# $regiao: distribuição uniforme
plot(Despesas$regiao,  xlab = "região")
```

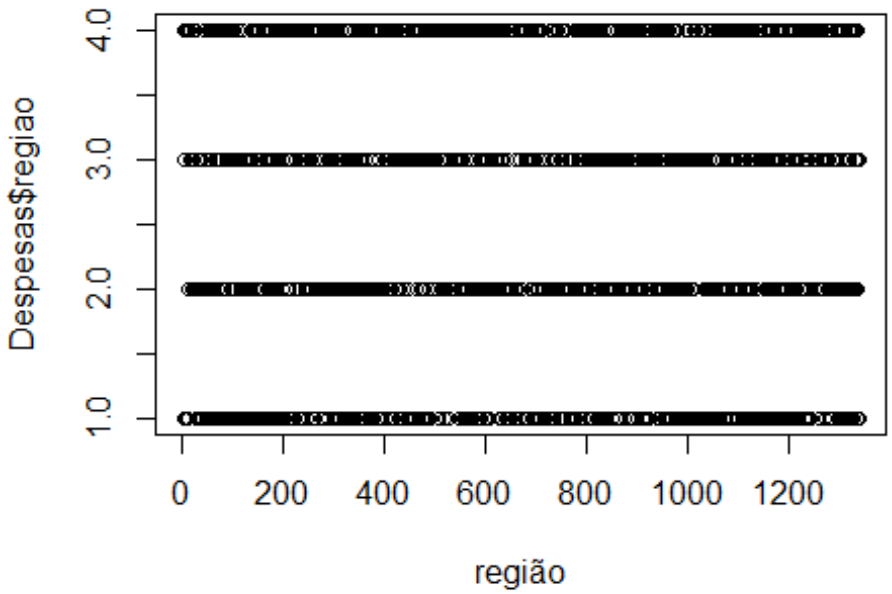


```r
table(Despesas$regiao)
```

```
##
##   1   2   3   4
## 325 324 325 364
```

Explorando relacionamento entre as variáveis:

Matriz de Correlação

```r
Data_Cor <- cor(Despesas)
Data_Cor
```

```
##               idade        sexo          bmi      filhos      fumante
## idade    1.00000000  0.02085587  0.109341015  0.04246900 -0.025018752
## sexo     0.02085587  1.00000000 -0.046380206 -0.01716298 -0.076184817
## bmi      0.10934101 -0.04638021  1.000000000  0.01264471  0.003968054
## filhos   0.04246900 -0.01716298  0.012644707  1.00000000  0.007673120
## fumante -0.02501875 -0.07618482  0.003968054  0.00767312  1.000000000
## regiao  -0.00521169 -0.01612099  0.261848704 -0.01925722  0.053929632
## gastos   0.29900819 -0.05729207  0.198576255  0.06799823  0.787251430
##               regiao      gastos
## idade   -0.00521169  0.29900819
## sexo    -0.01612099 -0.05729207
## bmi      0.26184870  0.19857626
## filhos  -0.01925722  0.06799823
## fumante  0.05392963  0.78725143
## regiao   1.00000000  0.05699279
## gastos   0.05699279  1.00000000
```

```
# Visualizando relacionamento entre as variáveis:
corrplot(Data_Cor, method = "circle")
```

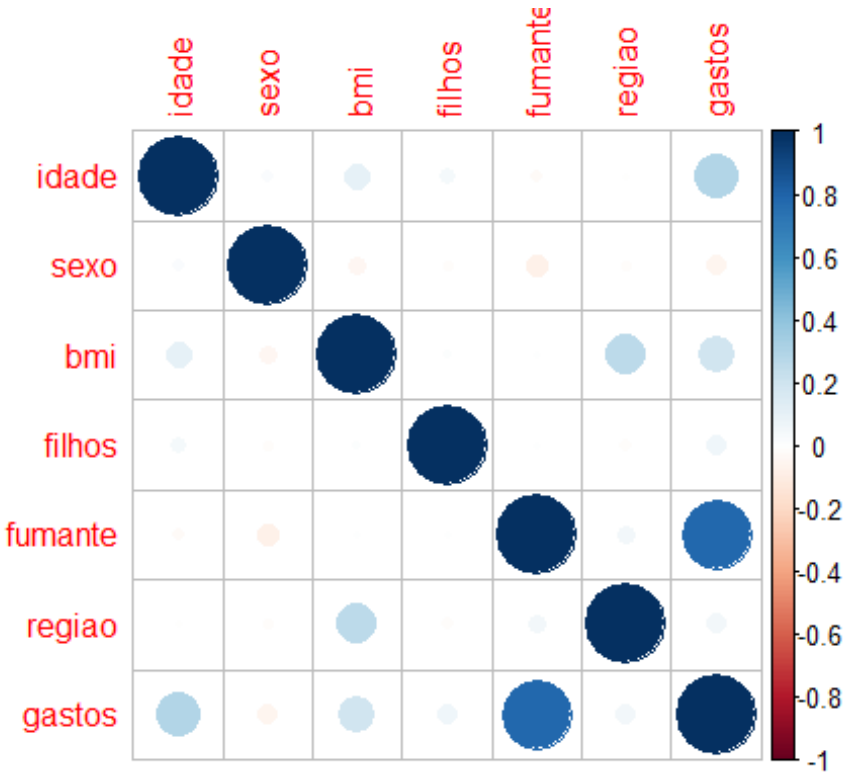

O objetivo do estudo da correlação é determinar (mensurar) o grau de relacionamento entre duas variáveis. Existem algumas associações interessantes. Pode-se destacar que a correlação entre as variáveis é positiva e moderada. Por ordem de força temos a fumante, idade e bmi. Estas associações implicam que, à medida que elas aumentam, o custo esperado do seguro saúde sobe!

Etapa 3 - Modelagem

Treinando o Modelo. No modelo é usado a Regressão Linear Múltipla. Formula da Regressão Linear múltiplas Estimada:

y = a + b0x1 + b1x2 + Xnxn

Criando amostras randômicas:

```
# Criando amostras randômicas
set.seed(101)
Amostra <- sample.split(Despesas, SplitRatio = 0.70)

# Treinamos o nosso modelo nos dados de treino
# Dados_Treino
Dados_Treino <- subset(Despesas, Amostra == TRUE)
summary(Dados_Treino)
```

```
##      idade            sexo            bmi           filhos
##  Min.   :18.00   Min.   :1.000   Min.   :16.0   Min.   :0.000
##  1st Qu.:26.00   1st Qu.:1.000   1st Qu.:26.3   1st Qu.:0.000
##  Median :40.00   Median :1.000   Median :30.5   Median :1.000
##  Mean   :39.28   Mean   :1.486   Mean   :30.7   Mean   :1.111
##  3rd Qu.:52.00   3rd Qu.:2.000   3rd Qu.:34.7   3rd Qu.:2.000
##  Max.   :64.00   Max.   :2.000   Max.   :53.1   Max.   :5.000
##     fumante          regiao          gastos
##  Min.   :1.000   Min.   :1.000   Min.   : 1136
##  1st Qu.:1.000   1st Qu.:2.000   1st Qu.: 4828
##  Median :1.000   Median :3.000   Median : 9635
##  Mean   :1.205   Mean   :2.558   Mean   :13551
##  3rd Qu.:1.000   3rd Qu.:4.000   3rd Qu.:17180
##  Max.   :2.000   Max.   :4.000   Max.   :63770

# Fazemos as predições nos dados de teste
# Dados_Teste
Dados_Teste <- subset(Despesas, Amostra == FALSE)

# O modelo utilizado aqui é o de Regressão Linear. No modelo1 estou consi
derando
# todas as variaveis do dataset.
Modelo_v1 <- lm(gastos ~ ., Despesas)
```

Etapa 4 -Interpretando o Modelo

Nesta etapa iremos analisar o resumo dos parâmetros do Modelo_v1.

```
summary(Modelo_v1)

##
## Call:
## lm(formula = gastos ~ ., data = Despesas)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -11573.9  -2899.6   -974.5   1418.2  29955.5
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -35842.8     1213.2 -29.545  < 2e-16 ***
## idade          256.9       11.9  21.597  < 2e-16 ***
## sexo           129.0      333.0   0.387  0.69853
## bmi            337.1       28.4  11.872  < 2e-16 ***
## filhos         468.6      137.7   3.402  0.00069 ***
## fumante      23866.0      412.7  57.832  < 2e-16 ***
## regiao        -298.0      152.3  -1.957  0.05057 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6063 on 1331 degrees of freedom
```

```
## Multiple R-squared:  0.7505, Adjusted R-squared:  0.7493
## F-statistic: 667.1 on 6 and 1331 DF,  p-value: < 2.2e-16
```

Avaliando os parâmetros:

O primeiro parâmetro a ser analisado é o nível de significância de acordo com o p-value. O nível de significância é o limite para o p-valor, abaixo do qual assume-se que a hipótese nula é falsa. O p-valor é a probabilidade de se obter uma estatística de teste igual ou mais extrema que a estatística observada a partir de uma amostra de uma população quando ela é verdadeira. Isto significa que o nível de significância é a probabilidade de se rejeitar incorretamente a hipótese nula quando ela é verdadeira. O nível de significância corresponde ao erro do tipo I, cujos valores mais comuns são 10%, 5% e 1%. Iremos considerar o de 10%.

Pode-se observar que as variáveis idade, bmi, filhos, fumante, regiao têm o nível de significância < 10%. Já as outras variáveis não influenciam tanto no modelo. Nesse sentido teremos que elaborar outro modelo, retirando as variáveis que não influenciam ou pouco influenciam na variável dependente. Retirando essas variáveis os valores das variáveis significativas e da interceptação serão alterados.

```
Modelo_v2 <- lm(gastos ~ idade + bmi + filhos + fumante + regiao, Despesa
s)
summary(Modelo_v2)
```

```
##
## Call:
## lm(formula = gastos ~ idade + bmi + filhos + fumante + regiao,
##     data = Despesas)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -11634.9  -2890.5   -964.4   1392.1  29899.4
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -35623.28    1072.30 -33.221  < 2e-16 ***
## idade          257.07      11.89  21.620  < 2e-16 ***
## bmi            336.60      28.35  11.871  < 2e-16 ***
## filhos         467.64     137.68   3.397 0.000702 ***
## fumante      23853.93     411.38  57.986  < 2e-16 ***
## regiao        -297.97     152.23  -1.957 0.050517 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6061 on 1332 degrees of freedom
## Multiple R-squared:  0.7504, Adjusted R-squared:  0.7495
## F-statistic:   801 on 5 and 1332 DF,  p-value: < 2.2e-16
```

Comparando os parâmetros dos dois modelos conforme pressuposições abaixo: a) Multicolinearidade

```
vif(Modelo_v1)

##    idade     sexo      bmi   filhos  fumante   regiao
## 1.016252 1.008878 1.090591 1.002746 1.009406 1.078632

vif(Modelo_v2)

##    idade      bmi   filhos  fumante   regiao
## 1.015620 1.088195 1.002453 1.003691 1.078632
```

Não há multicolinearidade nos dois modelos

b) Parcimônia No Modelo_v1 temos algumas variáveis que não contribuem para o modelo. Sendo asim, o Modelo_v2 ganha nesse ponto

c) Residuais

```
Res_1 <- residuals(Modelo_v1)
Res_2 <- residuals(Modelo_v2)

# Convertendo o objeto para um dataframe
Res_1 <- as.data.frame(Res_1)
head(Res_1)

##         Res_1
## 1 -8655.88369
## 2 -1722.91135
## 3 -2235.91837
## 4 17998.32688
## 5 -1952.47571
## 6    38.01796

ggplot(Res_1, aes(Res_1)) +
geom_histogram(bins = 20, fill = 'blue')
```

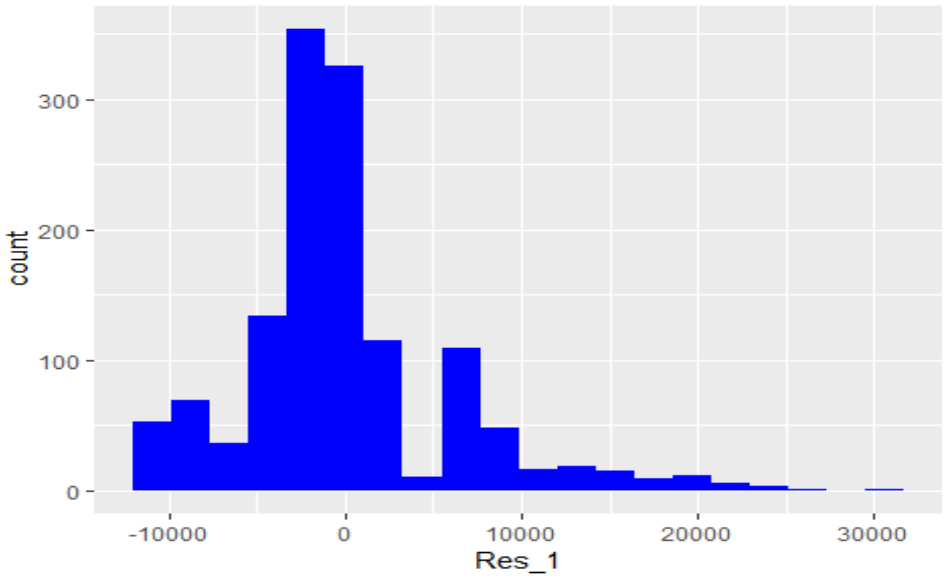

```r
Res_2 <- as.data.frame(Res_2)
head(Res_2)
```

```
##        Res_2
## 1 -8581.2590
## 2 -1785.2731
## 3 -2298.0197
## 4 17927.6929
## 5 -2019.7981
## 6    98.0721
```

```r
ggplot(Res_2, aes(Res_2)) +
geom_histogram(bins = 20, fill = 'blue')
```

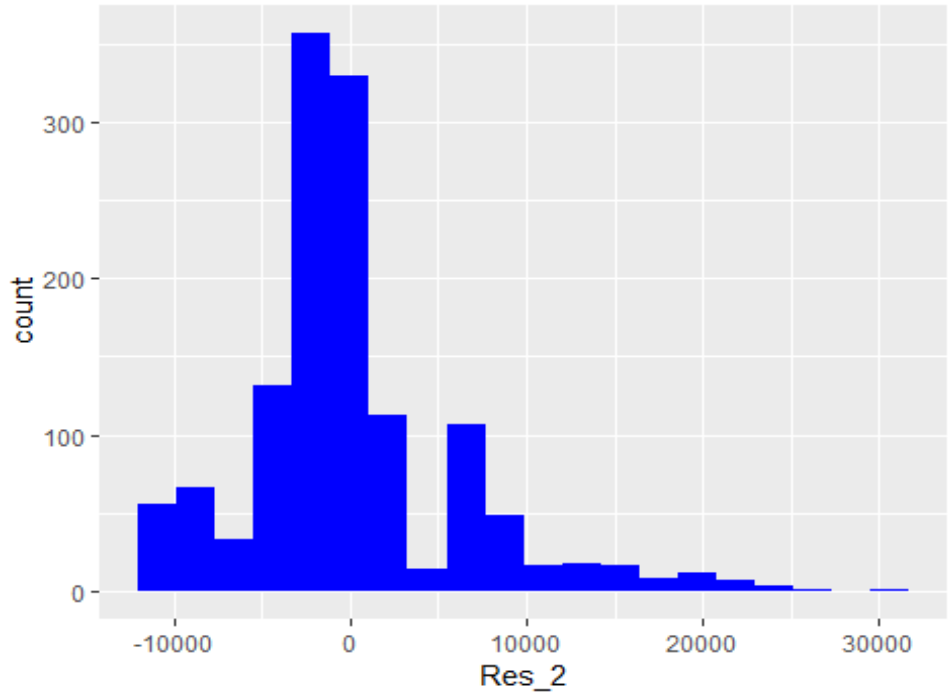

O histograma apresenta uma distribuição parecida com a normal, o que indica que a média entre os valores previstos e os valores observados é próximo de 0 (o que é bom).

d) Os valores de correlação são muito próximos.

e) p-value são iguais

Resultado: Baseado nos itens acima seguirei com o Modelo_v2.

Interpretação dos parâmetros:

Coeficientes: Como pode ser observado os valores estimados mudaram no Modelo_v2. Com isso temos a equação da regressão linear múltipla:

gastos = -35623.28 + 257.07idade + 336.60bmi + 467.64filhos + 23853.93fumante - 297.97regiao

Exemplo: Linha 20 do dataset Despesas

```
Despesas[20,]
```

```
##    idade sexo  bmi filhos fumante regiao   gastos
## 20    30    1 35.3      0       2      3 36837.47
```

gastos_20 = -35623.28 + 257.07(30) + 336.60(35.3) + 467.64(0) + 23853.93(2) - 297.97(3)

```
gastos_20 = -35623.28 + 257.07*30 + 336.60*35.3 + 467.64*0 + 23853.93*2 - 297.97*3
gastos_20
```

```
## [1] 30784.75
```

gastos_20 = 30784.75 gastos real = 36837.47 –> Taxa de acerto de 83,6%

Residual standard error:

Temos um dp = 6061 dos resíduos, e um grau de liberdade = 1332

Multiple R-squared:

Quanto mais próximo de 1 melhor. No nosso caso temos um R^2 = 0.7504. o que indica que 75,04% da variável dependente consegue ser explicada pelas variáveis explanatórias presentes no modelo.

Adjusted R-squared:

Ele deve ser menor que R^2. No nosso caso temos 0.7495.

F-statistic: Esse teste obtém os parâmetros do nosso modelo e compara com um modelo que tenha menos parâmetros

p-value: Temos uma probabilidade < 2.2e-16 que a variável não seja relevante.

Etapa 5 - Previsão

Prevendo despesas médicas Usando a função predict conseguimos realizar a previsão do modelo baseado nas no arquivo de teste

```
Previsao_v2 <- predict(Modelo_v2, Dados_Teste)
# Abaixo temos o cabeçalho das 10 primeiras previsões
head(Previsao_v2, 10)
```

```
##         3         4         7        10        11        14        17
##  6747.480  4056.777 10574.033 12041.036  2880.393 14831.323 11837.198
##        18        21        24
##  1558.411 15176.431 31434.198
```

```
# Visualizando os valores previstos e observados
Resultados <- cbind(Dados_Teste$gastos, Previsao_v2)
```

```r
colnames(Resultados) <- c('Real', 'Previsto')
Resultados <- as.data.frame(Resultados)
# Estamos prevendo os gastos e eles não podem ser negativos. Vamos verifi
car
min(Resultados)
```

```
## [1] -1518.167
```

```r
# Tratando os valores negativos com os valores minimos
Trata_min <- function(x){
  if  (x < 0){
    return(1122)
  }else{
    return(x)
  }
}
# Aplicando a função para tratar valores negativos em nossa previsão
Resultados$Previsto <- sapply(Resultados$Previsto, Trata_min)
Resultados$Previsto
```

```
##   [1]  6747.4797  4056.7771 10574.0329 12041.0361  2880.3933 14831.322
8
##   [7] 11837.1984  1558.4106 15176.4307 31434.1979  7804.3236 14047.214
9
##  [13] 28829.2311  1114.5909 31108.5508  1021.8258 33306.9650  8262.814
4
##  [19] 10358.8801 14030.7157 10709.5404  5576.2500 33422.3966 40086.076
7
##  [25] 32693.0750 10163.5459 13166.6753  1948.8584 17114.2792 27571.965
4
##  [31] 11822.7415 13187.5804  4924.8121  9580.3312  5126.0526 16010.507
6
##  [37] 36941.4264 10888.0777  5733.0270  9579.1011 39113.8886 14069.350
1
##  [43]  8513.1450  3930.1009  5801.2436  5952.7489  3884.9453 12407.801
4
##  [49] 13243.7233 12685.5584  8790.6448   273.0799  2835.5249  4012.630
8
##  [55] 26939.5534  9720.6990 13980.6162  2152.8032  3699.2011  5109.947
8
##  [61] 29084.3084  6320.0220 35280.9942  2248.1956  5509.7949 30161.950
3
##  [67] 31445.0114 24598.2511 31537.0543  6528.9408  7407.6118  8736.975
1
##  [73] 17203.0131 10132.0884  5311.1883 11514.7936  9824.9227  4557.903
3
##  [79]  9618.7083 36249.6527  9182.7471  5410.1507  2116.1511  3117.025
8
##  [85]  7135.5873 17315.4897 11435.1482  5028.0630 11092.0226 12253.090
3
##  [91]  4630.7661  5233.9901 10510.8567  1017.5741  7888.1907 27788.749
```

```
2
##  [97]  7061.2437 16052.3242 11382.1707 12227.8968  7140.3406  8868.702
3
## [103] 30689.8109  4024.4839 37007.7378  5292.4496  1122.0000 39159.766
4
## [109] 35045.9561 11726.0120 11126.7525 25522.6497 34438.4738 38392.676
2
## [115]  9537.8028  9382.9781 11895.6879  9605.7688   686.2609  7887.432
0
## [121]  5104.6095 13146.9638 16585.6967 10695.4779  5777.1732  2388.426
3
## [127] 25398.8581 31992.1891  7582.2852  6279.8403 15715.7499  6427.314
4
## [133]  9143.7183   535.1200 28700.8234 12556.8999  8533.8659  6152.472
0
## [139]  3947.2922  9863.1992 39487.7601 34376.9991 14115.7659 15401.818
7
## [145] 35681.8977  8655.3880 12348.9540  7044.4403  8507.6632  2174.533
6
## [151]  4372.6605  7966.3617 15043.6577  1122.0000 11781.4798  2089.119
1
## [157] 14305.6483  8079.8411 10716.0617 29883.9426  3389.0137 30593.773
4
## [163] 25423.5736 35961.0219  7319.8507 10271.0119  2223.6537  5405.935
6
## [169] 11267.3476  6456.1445 13341.3186 15577.2207 15492.8521 14863.031
0
## [175]  5312.5490  5830.6523 24897.2240 10543.3642 11884.4133 37070.084
8
## [181] 33279.5386  4361.4526  7060.1572  6509.1522  3362.5967 13027.136
7
## [187]  3960.5190  7464.8347  7376.3280 14959.3662 35637.2800 10979.111
2
## [193]  9196.3617  4224.4642 11852.2638 12851.8783 15061.9719 32085.569
2
## [199]  1299.3622 28631.8780  3479.6828  2393.6875  2251.8023 37461.177
6
## [205]  4857.8556  3924.5890  2235.3331  6072.1515 10454.1588 12526.876
3
## [211]   710.6656 17626.3992  4184.9276 16469.7270 30224.7687 25976.059
5
## [217]  4625.1471  2277.5272 13303.0486  2453.7649 31209.7828 10702.363
6
## [223]  9710.9718 10142.7949 30942.4815  9599.1404 13189.5992 14243.164
2
## [229] 17123.4749  7295.7803  8790.0298  3819.3860 15452.6704 34002.512
6
## [235]  3688.2438 37497.6561 10478.1691  3481.0501 11169.9730  4766.387
2
## [241]  4543.9544 15439.5873 11834.9654 38727.1912  5100.9728 16461.146
```

```
3
## [247]  1715.2175 32749.9466 11852.6581  3710.0447  1122.0000 31159.940
5
## [253] 12008.0978  7079.8687 11143.6330  8051.5190 10299.1605 11679.746
3
## [259] 26196.7608 11627.3472  4856.1541  9754.3595  3437.1610 35762.158
1
## [265] 26918.5517 13963.3949  7570.2884  4139.3070  8019.8708 36225.080
8
## [271]  6443.1385  6493.5488  1531.3786 14648.5938 12430.1403  7029.267
9
## [277]  7244.9286  7196.8113 14943.2914 11760.7589 14054.1411  6984.005
1
## [283] 13605.2339 10237.6792 35086.8234 34045.1480 38198.0705  5591.679
7
## [289] 37915.8111  6703.9849 15286.7749  1122.0000 34033.6528 11080.844
7
## [295]  7998.6484 28769.5115  4447.6192  8147.8907 13066.8105  7115.117
2
## [301] 14632.3518  6026.9188 36827.6897  6213.0273  3982.0692  6408.505
2
## [307]  8603.8141 12003.7690 14444.8761  4136.7868 10077.6299 26749.163
1
## [313] 29506.0700  8632.2134 14711.5558  2933.2574 29474.4284 27662.323
7
## [319]  9672.3375 11385.4131 12004.2404  3092.5911 17142.2136  5829.315
1
## [325]  9338.6112 28378.1679 29263.4608 13289.4640 10758.8043  5200.252
6
## [331] 11231.6748 26398.7234 10022.9208 11285.0468 28518.7094 33801.887
1
## [337] 15513.0351  5751.7656 11134.4073 31552.2268  9631.2129  3522.569
0
## [343]  7122.2169 15608.7552  1871.3024  5136.6521  1797.7475 12259.103
7
## [349]  8807.6154  2783.1258 32823.7522   574.2923  2134.3518 15726.235
7
## [355] 33798.6748  5797.5298  4076.9901 10888.5792  7194.1539 13668.954
5
## [361] 28781.1138 35576.2702 12426.6171 13111.9361 31367.4920 10205.673
3
## [367] 34373.4695 26325.4192 37659.7543  3587.5132  8996.8592 17166.755
4
## [373] 12375.1203  4119.9533  7720.1693  9102.7310  8038.2922  3535.795
8
## [379]  5217.2232 29314.3125  6288.0631  7925.2307  9594.7815 17828.361
8
## [385]  5231.1121   390.5304  4910.6425  5149.8723  6951.7119 27697.244
3
## [391] 13489.8322  8371.9049 31895.1018  8015.5890 11689.9449  8723.360
```

```
5
## [397]  1032.8131  9222.8922  9842.2276 10786.8457  8721.8432  8442.277
5
## [403]  1122.0000 15877.1730 16407.3800 32979.5863  9265.1698 39378.669
6
## [409] 30352.0900  8771.3277 34791.2666  3509.7065 15550.0450  5923.668
0
## [415]  2619.1055 10948.0717   387.5387 26651.7885 12909.4355  6357.616
9
## [421] 29280.6821  5343.2243 10521.2290 24558.6073  1152.8609  6800.821
6
## [427] 10243.4420 15654.6330 28175.7639  9639.3992  6647.2570 34763.870
2
## [433]  7350.4894 29647.5608  6395.5291  6467.6033 15267.6014 28385.799
2
## [439] 14836.6911  4381.6355 11855.0047 36879.8016  4737.9514 10363.125
4
## [445]  3018.0268  2941.5102 26963.7074 32089.8510  7137.3188 34187.976
0
## [451] 10729.3956 34706.4972  9403.7761  8003.6589  3979.6925  8216.859
5
## [457] 12868.5617 12033.2913 33359.7990 12179.4217  9218.5333  1784.807
9
## [463]  1122.0000  5984.0327 15072.4878 13188.4827 16929.8723 11804.153
0
## [469] 13404.1671  4701.8309 11403.2194 11991.0437  8055.2328 11422.392
9
## [475]  4586.2255  6876.3888 33352.8363 12652.0050 10476.1034  3779.665
2
## [481] 39234.7251  5949.1121 11539.8434  1122.0000  7447.3862  7459.974
3
## [487]  7530.3940  2089.0120 12847.7336  8871.9446 11997.6421  3811.677
6
## [493]  2461.0084 15128.5707 11533.6695  2589.6968  3076.1219 10885.336
9
## [499]  8465.9300  5417.3942  8346.6044 32167.1197 15538.1920  2114.168
9
## [505]  5294.7191 28892.5509  3962.5013  8081.8234 30313.9571  2674.178
9
## [511] 13918.1621 12591.5698 26768.9882  4925.4572  6558.8874 12085.038
8
## [517] 15152.7482 32622.9061  8055.7707 12848.3787  5876.8173  7984.305
2
## [523]  3185.9646  6671.7988  6686.9008 11292.5045 13013.6592 23669.958
5
## [529]  8899.6217  5084.7909  6189.9899 40734.5635  2160.7218  5052.270
5
## [535]  5062.8099 31492.2931 25521.2825 10890.8187 14698.3656  8811.365
7
## [541]  7504.6991  8922.6893 11741.8060  9564.2499  6494.9226  5794.000
```

```
1
## [547]  3522.9333  6155.9416 10586.8653  2231.7264 39558.0726  5776.808
9
## [553]  5070.5847 27822.4096 11026.9712  4091.9119  6607.7569 39528.694
0
## [559] 31501.1544  2532.2937 27782.7658  5403.1946 10984.9509  2255.439
0
## [565] 11865.7714  7746.2284 16037.1152 14591.9859  9505.7668 14632.381
9
## [571] 17153.3080 12623.6358  1419.5171
```

Etapa 6 - Avaliando a Performance

Calculando o erro médio: Quão distantes seus valores previstos estão dos valores observados. Serve para avaliar as versões do modelo

```
# MSE
mse <- mean((Resultados$Real - Resultados$Previsto)^2)
print(mse)

## [1] 33844649

# RMSE
rmse <- mse^0.5
rmse

## [1] 5817.615

# Calculando R Squared
SSE = sum((Resultados$Previsto - Resultados$Real)^2)
SST = sum((mean(Despesas$gastos) - Resultados$Real)^2)

# R-Squared
# Ajuda a avaliar o nível de precisão do nosso modelo. Quanto maior, melh
or, sendo 1 o valor ideal.
R2 = 1 - (SSE/SST)
R2

## [1] 0.7607692
```

Etapa 7 - Otimização do Modelo

Nesta etapa será realizado alguns teste para ver se é possível melhorar o modelo

Modelo_v3: Retirando as observações de outlier.

```
Despesas_v3 <- Despesas
Despesas_v3 <- subset(Despesas_v3, Despesas_v3$gastos < 34490)
summary(Despesas_v3)

##      idade            sexo            bmi            filhos
##  Min.   :18.00   Min.   :1.00   Min.   :16.0   Min.   :0.000
```

```
##  1st Qu.:26.00   1st Qu.:1.00   1st Qu.:25.8   1st Qu.:0.000
##  Median :39.00   Median :2.00   Median :29.7   Median :1.000
##  Mean   :38.99   Mean   :1.51   Mean   :30.1   Mean   :1.084
##  3rd Qu.:51.00   3rd Qu.:2.00   3rd Qu.:33.8   3rd Qu.:2.000
##  Max.   :64.00   Max.   :2.00   Max.   :53.1   Max.   :5.000
##     fumante          regiao        gastos
##  Min.   :1.000   Min.   :1.0   Min.   : 1122
##  1st Qu.:1.000   1st Qu.:1.0   1st Qu.: 4409
##  Median :1.000   Median :2.0   Median : 8410
##  Mean   :1.115   Mean   :2.5   Mean   : 9928
##  3rd Qu.:1.000   3rd Qu.:4.0   3rd Qu.:12954
##  Max.   :2.000   Max.   :4.0   Max.   :34473
```

```
Modelo_v3 <- lm(gastos ~ ., Despesas_v3)
summary(Modelo_v3)
```

```
##
## Call:
## lm(formula = gastos ~ ., data = Despesas_v3)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -5327.3 -1862.6 -1290.4  -579.4 24491.8
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -18043.572   1090.779 -16.542  < 2e-16 ***
## idade          242.377      9.495  25.527  < 2e-16 ***
## sexo           363.552    264.796   1.373 0.170026
## bmi             67.960     23.609   2.879 0.004067 **
## filhos         406.064    109.047   3.724 0.000205 ***
## fumante      14688.923    429.272  34.218  < 2e-16 ***
## regiao        -357.245    120.928  -2.954 0.003196 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4579 on 1192 degrees of freedom
## Multiple R-squared:  0.6022, Adjusted R-squared:  0.6002
## F-statistic: 300.7 on 6 and 1192 DF,  p-value: < 2.2e-16
```

Comparação:

Modelo_v1 -> Adjust R-squared: 0.7493 e Multiple R-squared: 0.7505

Modelo_v2 -> Adjust R-squared: 0.7495 e Multiple R-squared: 0.7504

Modelo_v3 -> Adjust R-squared: 0.6002 e Multiple R-squared: 0.6022

Fazendo a previsão com o Modelo_v1

```r
Previsao_v1 <- predict(Modelo_v1, Dados_Teste)
# Abaixo temos o cabeçalho das 10 primeiras previsões
head(Previsao_v1, 10)
```

```
##         3         4         7        10        11        14        17
##  6685.378  3986.143 10637.244 12097.895  2812.455 14895.774 11898.437
##        18        21        24
##  1489.464 15238.520 31510.101
```

```r
# Visualizando os valores previstos e observados
Resultados <- cbind(Dados_Teste$gastos, Previsao_v1)
colnames(Resultados) <- c('Real', 'Previsto')
Resultados <- as.data.frame(Resultados)
# Estamos prevendo os gastos e eles não podem ser negativos. Vamos verifi
car
min(Resultados)
```

```
## [1] -1460.366
```

```r
# Tratando os valores negativos com os valores minimos
Trata_min <- function(x){
  if  (x < 0){
    return(1122)
  }else{
    return(x)
  }
}
# Aplicando a função para tratar valores negativos em nossa previsão
Resultados$Previsto <- sapply(Resultados$Previsto, Trata_min)
Resultados$Previsto
```

```
##   [1]  6685.3784  3986.1431 10637.2443 12097.8948  2812.4548 14895.773
6
##   [7] 11898.4368  1489.4644 15238.5198 31510.1007  7737.7847 14110.079
5
##  [13] 28778.4838  1176.5056 31058.4374   950.9595 33256.2304  8330.310
7
##  [19] 10295.9785 13965.0238 10765.6429  5643.4346 33365.6537 40033.793
2
##  [25] 32762.0966 10231.1441 13094.4208  2011.9701 17179.6452 27517.252
2
##  [31] 11884.2665 13119.6935  4988.0180  9643.0857  5058.6964 16080.329
8
##  [37] 37013.4425 10946.0607  5801.3456  9516.2981 39186.9166 14004.145
2
##  [43]  8575.1205  3861.2268  5862.8207  5888.9694  3817.3663 12469.010
3
##  [49] 13178.5085 12614.8347  8849.4036   204.7084  2898.6306  4074.915
2
##  [55] 27009.3559  9657.4425 14045.2517  2215.1292  3635.9967  5176.375
5
```

```
##  [61] 29028.6649  6255.2791 35227.6495  2182.9634  5440.5640 30231.640
1
##  [67] 31385.4727 24542.6299 31608.4226  6592.8447  7340.0757  8803.600
3
##  [73] 17138.5387 10063.4769  5376.0512 11445.9514  9886.7536  4625.948
0
##  [79]  9552.6712 36203.3064  9245.9430  5469.9167  2047.8975  3052.074
0
##  [85]  7189.5102 17378.8205 11491.0788  5091.0801 11020.2224 12192.072
8
##  [91]  4565.9791  5295.1261 10568.9323  1077.1437  7952.9645 27737.934
2
##  [97]  6999.0387 16117.6280 11447.3713 12157.6034  7071.7672  8808.129
3
## [103] 30770.3638  4083.4203 37077.2312  5229.5700  1122.0000 39233.373
4
## [109] 34990.0601 11785.9436 11058.5706 25597.4748 34381.2143 38345.381
2
## [115]  9470.5105  9312.9861 11833.3812  9666.3275   617.9753  7943.984
7
## [121]  5037.7292 13208.6824 16657.4555 10627.2154  5841.5708  2451.113
1
## [127] 25344.3824 31934.1920  7516.5374  6345.8252 15781.0085  6492.313
1
## [133]  9073.0842   596.0663 28776.3332 12489.0314  8593.4915  6218.813
1
## [139]  3879.3809  9798.5210 39561.1661 34318.6333 14175.2938 15333.648
7
## [145] 35627.1706  8715.6605 12406.7121  7108.7390  8445.5198  2108.138
1
## [151]  4433.8894  7902.1441 14985.1076  1122.0000 11844.8625  2151.623
1
## [157] 14369.0226  8140.1781 10770.3821 29833.1656  3325.2533 30545.139
4
## [163] 25494.0252 35903.9842  7249.4367 10201.6384  2282.7700  5473.487
1
## [169] 11330.9601  6382.5728 13270.3820 15518.5897 15552.9633 14929.099
1
## [175]  5243.1628  5764.7223 24967.3780 10608.0546 11817.3877 37139.245
8
## [181] 33226.2186  4295.7826  7121.2001  6574.9084  3298.8767 13086.361
4
## [187]  3895.7610  7399.8435  7440.9882 15022.6818 35579.0046 11036.377
9
## [193]  9132.1828  4155.8080 11795.7522 12911.5050 14997.3510 32029.636
0
## [199]  1231.6262 28706.3788  3540.3282  2457.5615  2315.3781 37403.152
6
## [205]  4795.8364  3860.1229  2299.8202  6135.0471 10512.2231 12459.237
4
```

```
## [211]   771.9617 17563.1628  4245.7497 16533.2075 30172.5982 25922.895
7
## [217]  4561.1741  2210.6616 13235.5003  2388.6528 31154.2289 10636.194
3
## [223]  9769.7761 10212.2726 30885.4200  9657.8872 13126.9641 14302.806
3
## [229] 17058.3699  7228.1868  8850.5085  3885.6716 15514.5121 33945.488
7
## [235]  3750.5400 37578.9293 10403.4748  3413.3228 11104.2443  4703.961
9
## [241]  4477.9744 15379.2194 11902.8943 38677.9130  5162.8086 16524.380
7
## [247]  1647.8759 32829.3909 11781.3621  3769.8638  1122.0000 31234.995
4
## [253] 12066.7790  7006.9385 11081.0683  8116.1151 10234.2465 11611.632
5
## [259] 26271.6489 11689.4338  4790.1053  9820.1518  3502.6334 35838.932
9
## [265] 26995.8289 14026.5971  7626.9449  4199.8315  7954.7934 36302.612
6
## [271]  6508.4753  6423.9039  1593.1900 14584.5465 12374.1617  7097.855
4
## [277]  7176.3207  7257.4356 15011.8641 11826.4915 14115.8754  6921.296
5
## [283] 13549.0587 10294.7798 35153.7213 34121.7650 38140.8986  5654.856
7
## [289] 37997.6056  6631.3016 15223.0825  1122.0000 33982.6192 11011.613
4
## [295]  8056.9784 28716.7518  4384.3917  8216.0814 13129.6185  7184.925
0
## [301] 14569.0267  6087.9860 36903.8672  6273.5952  3920.4293  6348.514
3
## [307]  8661.1981 11931.7680 14510.4228  4074.2526 10137.1906 26820.433
0
## [313] 29450.7586  8559.4644 14774.4536  2865.7084 29424.3172 27607.673
4
## [319]  9601.6574 11446.5491 12068.7060  3026.5845 17075.8539  5763.230
9
## [325]  9278.6059 28329.1922 29207.9777 13349.7609 10692.3649  5258.213
5
## [331] 11295.8606 26473.9209  9958.2542 11215.3109 28464.0012 33873.705
4
## [337] 15446.6425  5689.8322 11201.8431 31490.3089  9695.4523  3582.262
7
## [343]  7182.1757 15670.3274  1803.6911  5203.7911  1732.5670 12330.615
2
## [349]  8744.4054  2847.4346 32895.1705   501.8849  2198.6842 15787.521
7
## [355] 33746.0308  5726.7048  4138.3173 10825.5046  7127.6552 13728.815
4
```

```
## [361] 28859.5987 35647.4787 12489.6949 13043.9812 31441.5718 10264.098
8
## [367] 34447.4137 26268.4550 37744.2896  3644.0595  8925.4914 17105.044
5
## [373] 12309.4359  4183.4524  7650.5632  9042.0833  7970.7378  3469.645
4
## [379]  5153.2153 29259.8439  6227.2981  7990.0559  9522.3757 17894.432
1
## [385]  5300.1879   450.3996  4845.8894  5214.2881  6889.5764 27768.673
4
## [391] 13550.0030  8432.3327 31966.5098  8080.4771 11746.1039  8659.365
9
## [397]  1094.9113  9278.0106  9785.4945 10850.2692  8660.5366  8505.280
0
## [403]  1122.0000 15946.4727 16342.1955 32927.3329  9197.9357 39330.146
7
## [409] 30296.9102  8710.4108 34738.7361  3570.1223 15612.2307  5855.926
6
## [415]  2553.1910 11016.1958   445.8773 26593.7172 12846.0147  6419.261
9
## [421] 29226.6323  5407.2328 10455.9943 24628.8706  1211.3873  6733.325
6
## [427] 10309.6695 15716.7841 28119.4800  9570.5417  6574.0919 34709.224
7
## [433]  7407.1232 29588.2018  6455.7870  6534.4654 15333.0387 28464.382
0
## [439] 14905.9231  4447.4564 11786.4888 36954.0241  4799.3120 10421.905
8
## [445]  2951.8251  2876.6791 26910.6921 32161.9469  7195.7417 34131.702
4
## [451] 10661.4660 34652.6194  9463.5550  7939.7740  3914.8021  8151.656
0
## [457] 12805.4678 11972.2511 33308.9836 12240.3618  9271.4964  1717.226
0
## [463]  1122.0000  5917.0542 15133.3620 13119.6277 16870.7698 11863.620
0
## [469] 13469.8352  4770.0194 11463.5983 11923.8292  7994.2364 11482.639
5
## [475]  4521.0137  6805.8372 33425.8014 12584.8238 10412.6343  3839.714
4
## [481] 39312.8730  6014.0487 11470.3361  1122.0000  7510.1481  7513.885
4
## [487]  7589.5328  2147.9220 12783.3957  8807.3071 11931.7690  3876.278
5
## [493]  2524.9855 15191.1760 11596.6342  2651.2893  3140.0239 10826.326
8
## [499]  8527.1723  5477.2521  8284.2952 32240.1895 15603.7256  2176.007
8
## [505]  5360.4934 28837.7501  4025.6453  8012.0679 30266.2301  2736.367
0
```

```
## [511] 13979.5360 12655.3760 26844.7529  4987.4136  6490.4408 12018.168
3
## [517] 15216.1270 32571.2376  7989.9309 12911.7886  5941.2154  7923.394
9
## [523]  3245.1427  6603.2826  6616.8486 11230.0486 12946.3285 23741.323
1
## [529]  8960.9718  5019.2924  6121.6008 40681.5045  2222.3607  4987.534
2
## [535]  5131.6280 31440.3049 25466.4856 10955.9275 14764.4570  8867.774
6
## [541]  7565.7525  8984.4694 11801.6053  9497.3876  6431.7788  5726.488
0
## [547]  3586.5023  6218.0290 10648.8842  2167.4055 39504.1151  5837.331
2
## [553]  5128.7749 27771.6462 10954.7245  4154.5454  6541.4199 39473.716
7
## [559] 31444.2877  2594.1836 27857.8868  5463.6203 10925.4709  2190.298
8
## [565] 11807.2883  7807.5805 15971.3636 14523.6738  9568.3263 14569.527
2
## [571] 17223.5067 12558.0607  1480.8006
```

```
# MSE
mse <- mean((Resultados$Real - Resultados$Previsto)^2)
print(mse)
```

```
## [1] 33787068
```

```
# RMSE
rmse <- mse^0.5
rmse
```

```
## [1] 5812.664
```

```
# Calculando R Squared
SSE = sum((Resultados$Previsto - Resultados$Real)^2)
SST = sum((mean(Despesas$gastos) - Resultados$Real)^2)
# R-Squared
# Ajuda a avaliar o nível de precisão do nosso modelo. Quanto maior, melh
or, sendo 1 o valor ideal.
R2 = 1 - (SSE/SST)
R2
```

```
## [1] 0.7611762
```

Previsão_v1 -> Multiple R-squared: 0.7611

Previsão_v2 -> Multiple R-squared: 0.7607

Conclusão

Neste projeto foi possível utilizar algumas técnicas de manipulação de dados, técnicas estatísticas, machine learning com a linguagem R. Foi um desafio prazeroso utilizar o R em todas as etapas do projeto. Tive dificuldades em algumas técnicas de manipulação de dados, mas com a ajuda do material fornecido pela DSA e das documentações do R, consegui vencer as mesmas.

Nessa perspectiva, afim de otimizar o modelo, foi realizado alguns testes manipulando o dataset, mas os resultados foram inferiores ou bem próximos do conquistado pelo Modelo_v2. Para melhorarmos o o resultado teríamos que possuir mais observações ou mais variáveis para treinar o modelo.

Baseado na comparação realizada no item anterior o melhor os Modelos v1 e v2 são muito parecidos. Porém o Modelo_v2 é um pouco melhor pois possui menos variaveis e tem o R ajustado um pouco maior. Neste modelo de machine learning podemos dizer que 75,04% da variável dependente consegue ser explicada pelo modelo.

Evanil Tiengo Junior

Belo Horizonte, 22 de outubro de 2018